

从勾股定理到 Transformer：基于关系体的注意力几何理论 (From Pythagoras to Transformers: A Geometric Theory of Attention via the Relation Body)

作者：王志方（独立研究者）

ORCID: 0009-0001-0374-3825

日期：2026-09-24

摘要

中文摘要

理解大型语言模型（LLMs）内部机制是当前人工智能研究的核心挑战之一。本文提出一个统一的几何框架——“关系体”（Relation Body），将任意两个向量之间的关系分解为两个正交状态：内积所度量的“相同/冗余”分量与外积所度量的“不同/独立”分量。二者的归一化满足 $c^2 + s^2 = 1$ ，即单位圆上的勾股定理。我们将这一框架应用于 Transformer 的注意力机制，推导出四个定理：关系体定理（T1）、冗余-概率定理（T2）、无主干定理（T3）与冗余补偿定理（T4）。在 GPT-2 small 与 GPT-2 medium 上的实验表明：注意力机制呈现“全局无主干、局部有叶柄”的灌木丛结构；高 PC1 的注意力头对应句法/位置功能，低 PC1 的头对应语义功能；Layer 0 与最后一层分别是信息入口与语义出口瓶颈，而中间层具有高度冗余补偿能力。进一步的受控输入领域实验直接验证了核心因果机制：输入语义分布越窄，PC1 越高，结构越接近具有主干的“传统树”。基于此，我们预测混合专家（MoE）模型中的单个专家应呈现比稠密模型更强的局部主干结构。本文为理解注意力机制的信息组织方式提供了可计算、可证伪的几何理论，并为大模型的可解释性研究开辟了“几何可解释性”新路径。

English Abstract

Understanding the internal mechanisms of large language models (LLMs) remains a central challenge in artificial intelligence. This paper proposes a unified geometric framework—the **Relation Body**—which decomposes the relationship between any two vectors into two orthogonal states: the “same/redundant” component measured by the inner product, and the “different/independent” component measured by the outer product. Their normalized forms satisfy $c^2 + s^2 = 1$, i.e., the Pythagorean theorem on the unit circle. We apply this framework to the attention mechanism of Transformers and derive four theorems: the Relation Body Theorem (T1), the Redundancy-Probability

Theorem (T2), the No-Trunk Theorem (T3), and the Redundancy Compensation Theorem (T4). Experiments on GPT-2 small and GPT-2 medium reveal that attention exhibits a “shrub” structure: no global trunk, but local stems. High-PC1 heads correspond to syntactic/positional functions, while low-PC1 heads correspond to semantic functions. Layer 0 and the final layer serve as information entry and semantic exit bottlenecks, respectively, while middle layers possess strong redundancy compensation. Controlled-domain experiments directly verify the core causal mechanism: the narrower the input semantic distribution, the higher the PC1, and the closer the structure is to a traditional tree with a trunk. Based on this, we predict that individual experts in Mixture-of-Experts (MoE) models should exhibit stronger local trunk structures than dense models. This work provides a computable, falsifiable geometric theory for understanding how attention organizes information, and opens a new path of “geometric interpretability” for large-model research.

关键词 / Keywords

注意力机制，可解释性，关系体，内积与外积，主成分分析，混合专家

Attention mechanism, interpretability, relation body, inner and outer product, principal component analysis, mixture of experts

1. 引言

1.1 问题背景

- Transformer 已成为 LLM 基础架构，但内部机制仍为黑箱。
- 现有可解释性方法：注意力可视化、探针、因果追踪、稀疏自编码器。
- 缺乏统一几何理论解释：为什么注意力有效？多头如何分工？层间如何协作？

1.2 现有方法的局限

- 自下而上、局部现象、彼此孤立。
- 未统一解释冗余性、层间信息流、跨模型普遍规律。

1.3 本文核心思想：关系体

- 任意两个非零向量的关系可由内积与外积完全刻画。
- 内积：相同/平行/冗余；外积：不同/正交/独立。
- 归一化后： $c^2 + s^2 = 1$ ，单位圆。
- 将注意力机制视为关系体上的信息组织过程。

1.4 主要贡献

1. 提出关系体几何，证明 T1，推导 T2、T3、T4。
2. 在 GPT-2 small/medium 上验证“无主干灌木丛”结构。
3. 发现高 PC1 头为句法/位置头，低 PC1 头为语义头。
4. 发现 Layer 11 存在全局语义广播头，类比“顶端优势”。
5. 消融实验证明入口/出口瓶颈与中间层冗余；累积消融发现相变点 $k^* \approx 4$ 。
6. 受控领域实验验证“语义越窄 $\rightarrow$ PC1 越高 $\rightarrow$ 越接近有主干的树”。
7. 预测 MoE 单个专家 PC1 显著高于稠密模型。

1.5 论文结构

- 第 2 节：关系体几何与四个定理。
- 第 3 节：实验设置与度量。
- 第 4 节：主要实验结果。
- 第 5 节：讨论与 MoE 预测。
- 第 6 节：结论与未来工作。

2. 关系体几何（理论）

本节建立论文的核心理论框架——**关系体几何**。我们从内积与外积的基本恒等式出发，证明任意两个非零向量的关系可归一化为单位圆上的点，进而推导出四个定理：关系体定理（T1）、冗余-概率定理（T2）、无主干定理（T3）与冗余补偿定理（T4）。这些定理将注意力机制中的概率分布、Value 向量的几何结构、以及层间信息流动统一在一个可计算、可证伪的数学框架内。

2.1 内积、外积与单位圆

2.1.1 关系坐标的定义

设 $a, b \in \mathbb{R}^d$ 为非零向量， $\langle \cdot, \cdot \rangle$ 为欧几里得内积， $\wedge$ 为外积（楔积）。定义**关系坐标**：

$$c(a, b) = \frac{\langle a, b \rangle}{\|a\| \|b\|}$$

$$s(a, b) = \frac{\|a \wedge b\|}{\|a\| \|b\|}$$

其中外积范数由下式给出：

$$\|a \wedge b\|^2 = \|a\|^2 \|b\|^2 - \langle a, b \rangle^2$$

这里 c 度量两个向量的**相同/平行**程度， s 度量**不同/正交**程度。二者分别对应内积与外积的归一化形式。

2.1.2 关系体定理 (T1)

定理 1 (关系体定理)

对任意非零向量 $a, b \in \mathbb{R}^d$ ，有

$$c^2 + s^2 = 1$$

即 (c, s) 落在单位圆 S^1 上。

证明

由外积范数恒等式：

$$\|a \wedge b\|^2 = \|a\|^2 \|b\|^2 - \langle a, b \rangle^2$$

两边除以 $\|a\|^2 \|b\|^2$ ：

$$\frac{\|a \wedge b\|^2}{\|a\|^2 \|b\|^2} = 1 - \frac{\langle a, b \rangle^2}{\|a\|^2 \|b\|^2}$$

即

$$s^2 = 1 - c^2$$

因此

$$c^2 + s^2 = 1$$

■

2.1.3 几何解释与信息论意义

设 a, b 的夹角为 θ ，则

$$c = \cos \theta, \quad s = |\sin \theta|$$

因此 $(c, s) = (\cos \theta, |\sin \theta|)$ ，这正是单位圆上的点。夹角 θ 对应关系体上的角度。

推论 1.1（信息守恒）

$$c^2 + s^2 = 1$$

可解释为：两个向量的共享信息比例 c^2 与独立信息比例 s^2 之和恒为 1。

推论 1.2（与勾股定理的联系）

关系体上的单位圆方程 $c^2 + s^2 = 1$ 与单位圆 $x^2 + y^2 = 1$ 在形式上完全一致。因此，关系体几何本质上是勾股定理在向量关系空间中的自然推广。




图 1 给出关系体单位圆示意图：横轴为 c （相同/平行），纵轴为 s （不同/正交）。圆上标注了平行（

$c = 1, s = 0$)、正交 ($c = 0, s = 1$) 与反向 ($c = -1, s = 0$) 三种极端关系。

2.2 冗余-概率定理 (T2)

2.2.1 注意力机制的基本设定

考虑 Transformer 中的单头注意力。给定输入序列 $X = [x_1, \dots, x_n] \in \mathbb{R}^{n \times d}$ ，通过线性投影得到 Query、Key、Value：

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

其中 $W_Q, W_K, W_V \in \mathbb{R}^{d \times d_h}$ 。注意力概率为

$$p_{ij} = \text{softmax} \left(\frac{q_i \cdot k_j}{\sqrt{d_h}} \right)$$

上下文加权平均为

$$\bar{V}_i = \sum_{j=1}^n p_{ij} V_j$$

定义**局部冗余度**：

$$\Delta_{ij} = \|V_j - \bar{V}_i\|$$

Δ_{ij} 越小，说明第 j 个 token 的 Value 越接近当前 query 的上下文均值，即信息冗余度越高。

2.2.2 假设

假设 A1 (QKV 对齐)

存在常数 $\lambda > 0$ ，使得对所有 i, j ：

$$q_i \cdot k_j \approx \lambda v_i \cdot v_j$$

即 Query-Key 相似度与 Value 相似度近似成正比。这是 Transformer 训练后常见的性质。

假设 A2 (V 空间局部聚集)

Value 向量在局部形成若干聚集，每个聚集有一个中心 μ_c 。

2.2.3 定理与证明

定理 2（冗余-概率定理）

在假设 A1 与 A2 下，注意力概率 p_{ij} 越高，则局部差异度 Δ_{ij} 的期望越小：

$$p_{ij} \uparrow \implies \mathbb{E}[\Delta_{ij}] \downarrow$$

证明

由 softmax 定义：

$$p_{ij} = \frac{\exp(q_i \cdot k_j / \sqrt{d_h})}{\sum_k \exp(q_i \cdot k_k / \sqrt{d_h})}$$

由 A1, $q_i \cdot k_j \approx \lambda v_i \cdot v_j$ ，因此

$$p_{ij} \approx \frac{\exp(\lambda v_i \cdot v_j / \sqrt{d_h})}{\sum_k \exp(\lambda v_i \cdot v_k / \sqrt{d_h})}$$

可知 p_{ij} 关于 $v_i \cdot v_j$ 单调递增。当 p_{ij} 高时， $v_i \cdot v_j$ 大，说明 V_j 与 v_i 方向一致。由 A2，局部聚集使得 $\bar{V}_i$ 也接近该聚集中心，因此

$$\bar{V}_i \approx V_j$$

从而

$$\Delta_{ij} = \|V_j - \bar{V}_i\| \approx 0$$

因此高概率对应高冗余度。■

2.2.4 推论

推论 2.1（熵与集中度负相关）

注意力分布越尖锐（熵越低），则加权平均越由少数高概率 token 主导，这些 token 的 Value 向量彼此相似，因此局部 PCA 的第一主成分集中度越高。即

$$\text{corr}(\text{熵}, \text{PC1 集中度}) < 0$$

推论 2.2（局部加权方差）

局部冗余度可用加权方差表示：

$$\sum_j p_{ij} \Delta_{ij}^2 = \text{Var}_p(V)$$

当 p_i 尖锐时方差小，当 p_i 弥散时方差大。

推论 2.3（全局无主干的解释）

若语义分布宽（高秩），则全局 Value 矩阵的奇异值谱接近 Marchenko-Pastur 分布，没有主导奇异值，因此全局 PC1 集中度趋近 $1/d_h$ 。这为 T3 提供了直观基础。

2.3 无主干定理（T3）

2.3.1 假设

假设 A3（宽语义）

训练数据的语义分布内在维度 D_{sem} 远大于头维度 d_h ：

$$D_{\text{sem}} \gg d_h$$

假设 A4（随机投影）

经过训练的 Value 投影矩阵 W_V 在语义空间中近似为随机正交投影，即 V 的行向量近似为独立同分布的随机向量。

2.3.2 定理与证明

定理 3（无主干定理）

在假设 A3 与 A4 下，全局 PC1 集中度趋近随机基线：

$$\frac{s_1^2}{\sum_{k=1}^r s_k^2} \rightarrow \frac{1}{d_h}$$

其中 $s_1 \geq s_2 \geq \dots \geq s_r$ 为 Value 矩阵 V 的奇异值。

证明

由 A4， V 的行向量近似独立同分布。协方差矩阵

$$C = \frac{1}{n} V^T V \in \mathbb{R}^{d_h \times d_h}$$

的特征值分布收敛到 Marchenko-Pastur 分布。MP 分布没有原子质量，即不存在孤立的大特征值。最大特征值近似为

$$\lambda_{\max} \approx \sigma^2(1 + \sqrt{\gamma})^2$$

其中 $\gamma = d_h/n$ 。总特征值之和为 $d_h \sigma^2$ 。因此

$$\frac{\lambda_{\max}}{\sum_k \lambda_k} = \frac{(1 + \sqrt{\gamma})^2}{d_h} = O\left(\frac{1}{d_h}\right)$$

当 d_h 有限时，PC1 集中度趋近 $1/d_h$ 。■

2.3.3 推论

推论 3.1（局部叶柄的存在）

全局无主干并不意味着局部无结构。对每个 query 取 top- k 个高概率 token，这些 token 语义相关，形成局部聚集，其协方差矩阵具有低秩结构，因此局部 PC1 集中度远高于随机基线。

推论 3.2（PC1 上界）

全局 PC1 集中度的理论上界为

$$\text{PC1}_{\max} = \frac{(1 + \sqrt{\gamma})^2}{d_h}$$

对于 GPT-2 small ($n = 31, d_h = 64$)， $\gamma \approx 0.48$ ，上界约 0.045。

推论 3.3（层间趋势）

语义维度 D_{sem} 在中间层最大，因此 PC1 最低；浅层处理词法/位置，语义窄，PC1 高；深层进行抽象压缩，语义维度降低，PC1 回升。即

$$\text{PC1} \propto \frac{1}{D_{\text{sem}}}$$

2.4 冗余补偿定理（T4）

2.4.1 设定

设模型有 L 层，每层 H 个头。第 l 层第 h 个头的注意力输出为 $A_{l,h}(X)$ 。定义消融操作 $do(A_{l,h} = 0)$ ，其因果效应为

$$\Delta_{l,h} = \|f(X) - f(X; \theta \setminus A_{l,h})\|$$

其中 f 为模型输出。

2.4.2 假设

假设 A5 (线性传播)

在消融幅度不大时，输出变化近似线性：

$$\Delta_{l,h} \approx \sum_{k=l}^L \gamma_k \cdot \text{dep}_{k,l,h}$$

其中 γ_k 为第 k 层对输出的贡献权重， $\text{dep}_{k,l,h}$ 为第 k 层对头 (l, h) 的依赖度。

假设 A6 (结构头/语义头二分)

结构头：PC1 高，熵低，编码位置/句法信息；语义头：PC1 低，熵高，编码语义信息。

2.4.3 定理与证明

定理 4' (冗余补偿定理)

在假设 A5 与 A6 下，消融效应满足

$$\Delta_{\text{Layer } 0} \gg \Delta_{\text{Layer } L-1} \gg \Delta_{\text{middle}} \gg \Delta_{\text{single head}}$$

证明要点

- **Layer 0 瓶颈**：Layer 0 是所有信息进入残差流的唯一通道，消融它等于切断输入，效应最大。
- **Layer L-1 出口**：最后一层直接输出到 logits，负责语义压缩，消融它破坏最终解码，效应次之。
- **中间层冗余**：由 T3，中间层语义维度最高，信息分散，消融一层可被其他层补偿，效应较小。
- **单头冗余**：多头设计中，每个头的贡献可被同层其他头部分补偿，效应最小。

因此上述不等式成立。■

2.4.4 补充与推论

补充 T4.1 (出口广播头)

出口层 (Layer $L - 1$) 的关键头为“全局广播头”，其注意力目标高度集中在句首 token。该头负责将句首的全局表示广播到所有位置，实现语义同步。

推论 4.1 (相变点)

累积消融中间层时，存在临界点 k^* ，当消融层数 $k > k^*$ 时，冗余补偿失效，性能急剧下降。实验表明 $k^* \approx 4$ 。

推论 4.2 (句法与语义的分化)

句法信息更依赖浅层，语义信息更依赖深层。因此消融浅层对句法影响更大，消融深层对语义影响更大。

2.5 可证伪预测

基于上述定理，我们提出以下可证伪预测：

- 1. **预测 1（语义宽度）**：输入语义分布越窄，PC1 集中度越高，结构越接近具有主干的“传统树”。
- 2. **预测 2（MoE 专家）**：混合专家模型中，单个专家由于训练语义窄，其 PC1 应显著高于稠密模型。
- 3. **预测 3（消融瓶颈）**：消融入口层（Layer 0）或出口层（最后一层）的效应远大于消融中间层。
- 4. **预测 4（功能分化）**：高 PC1 头对应句法/位置功能，低 PC1 头对应语义功能。

这些预测将在第 3–5 节的实验中进行检验。

小结

本节建立了关系体几何的完整理论框架。从内积与外积的归一化恒等式出发，证明了关系体定理（T1），并在此基础上推导了冗余-概率定理（T2）、无主干定理（T3）与冗余补偿定理（T4）。这些定理为后续实验提供了明确的假设与可证伪预测，也为理解注意力机制的信息组织方式提供了统一的几何语言。

3. 实验设置与度量

本节详细说明实验所用的模型、数据、度量指标与实验流程。所有实验基于 HuggingFace Transformers 实现，代码与数据将在论文接收后开源。

3.1 模型与数据

3.1.1 模型

本文使用两个规模的 GPT-2 模型进行实验：

模型	层数 L	头数 H	隐藏维度 d	头维度 d_h
GPT-2 small	12	12	768	64

模型	层数 L	头数 H	隐藏维度 d	头维度 d_h
GPT-2 medium	24	16	1024	64

选择 GPT-2 系列的原因：

- 架构标准，易于 Hook 与消融；
- 开源可复现；
- 两个规模可验证跨模型普遍性。

3.1.2 输入文本

基础文本：一段 31 token 的英文段落，用于单次前向传播分析：

"The cat sat on the mat. It was a sunny day and the cat wanted to play outside. The dog ran to the park and saw a bird."

受控领域文本：用于第 5 节受控领域实验，包含四种语义宽度：

领域	语义宽度	示例内容
repeat	极窄	重复 "the" 30 次
single	窄	纯 Python 代码（阶乘、斐波那契、二叉树）
double	中	数学 + 诗歌混合
multi	宽	新闻 + 代码 + 数学 + 对话混合

所有文本均使用 GPT-2 tokenizer 编码，不添加特殊 token。

3.2 度量指标

本文使用六类度量指标，分别对应不同的理论假设。

3.2.1 方案 A：局部差异度

定义

对每个注意力头，计算注意力概率 p_{ij} 与局部差异度 Δ_{ij} 的相关系数：

$$\Delta_{ij} = \|V_j - \bar{V}_i\|$$

其中

$$\bar{V}_i = \sum_j p_{ij} V_j$$

为当前 query i 的上下文加权平均。

度量

$$r_A = \text{corr}(p_{ij}, \Delta_{ij})$$

对所有因果有效的 (i, j) 对计算 Pearson 相关系数。

含义

- $r_A < 0$: 高概率 token 趋同于上下文均值，局部冗余；
- $r_A \rightarrow -1$: 强局部冗余；
- $r_A \rightarrow 0$: 无局部结构。

对应假设: H1（高概率对应高冗余）。

3.2.2 方案 B：全局主成分能量

定义

对整个序列的 Value 矩阵 $V \in \mathbb{R}^{n \times d_h}$ 做 SVD:

$$V = USV^T$$

取前 $K = 5$ 个主成分 $V^T[:5]$ 。对每个 token j ，计算其在前 5 个主成分方向上的能量占比：

$$\text{energy}_j = \frac{\|\text{proj}_{\text{top5}}(V_j)\|^2}{\|V_j\|^2}$$

度量

$$r_B = \text{corr}(\text{avg_}p_j, \text{energy}_j)$$

其中 $\text{avg_}p_j$ 为 token j 作为 key 被所有 query 关注的平均概率。

含义

- $r_B > 0$: 高概率 token 集中在全局主成分，存在全局主干；

- $r_B < 0$: 高概率 token 在全局主成分之外，无主干。

对应假设：H2（存在全局主干）。

3.2.3 方案 C：全局残差范数

定义

同方案 B 的 SVD 分解。对每个 token j ，计算其残差范数：

$$\text{residual}_j = \|V_j - \text{proj}_{\text{top5}}(V_j)\|$$

度量

$$r_C = \text{corr}(\text{avg_}p_j, \text{residual}_j)$$

含义

- $r_C < 0$: 高概率 token 残差小，被全局结构充分解释；
- $r_C > 0$: 高概率 token 残差大，全局结构无法解释。

对应假设：H3（全局主成分充分解释高概率 token）。

3.2.4 局部 PCA：局部树干强度

定义

对每个 query i ，取注意力概率最高的 top- k 个 token（本文 $k = 10$ ），提取其 Value 向量 $V_{\text{top}} \in \mathbb{R}^{k \times d_h}$ 。中心化后做 SVD：

$$V_{\text{top}} - \bar{V}_{\text{top}} = USV^T$$

定义局部 PC1 集中度：

$$\text{conc}_i = \frac{S_1^2}{\sum_k S_k^2}$$

度量

对所有 query 取平均：

$$\text{mean_conc} = \frac{1}{n} \sum_{i=1}^n \text{conc}_i$$

含义

- $\text{conc} \rightarrow 1$: top- k 的 Value 几乎共线，强局部树干；
- $\text{conc} \rightarrow 1/d_h$: 完全随机分散，无局部结构；
- 实验中观察到均值约 0.34，远高于随机基线 0.0156。

对应假设：H4（局部存在叶柄，但强度有限）。

3.2.5 消融效应

定义

对指定头或层进行消融（输出置零），测量模型在测试集上的性能变化：

$$\Delta = \text{score}_{\text{after}} - \text{score}_{\text{baseline}}$$

测试集

- **句法测试集：**60 题，覆盖主谓一致、时态、代词、冠词、介词；
- **语义测试集：**60 题，覆盖词义选择、常识推理。

评分函数

使用 log 概率差作为连续指标：

$$\text{score} = \log P(\text{correct} \mid \text{context}) - \log P(\text{wrong} \mid \text{context})$$

消融粒度

1. **单头消融：**置零单个注意力头的输出；
2. **整层消融：**置零某层所有头的输出；
3. **累积消融：**按层号从小到大逐步消融多个中间层；
4. **激活修补：**将指定头的输出替换为该头在所有 token 上的均值。

对应假设：T4（入口/出口瓶颈，中间层冗余）。

3.2.6 受控领域实验指标

定义

对每种输入领域，重复上述所有度量（方案 A/B/C、局部 PCA），得到该领域的平均 PC1 集中度。

核心检验

验证单调性：

$$PC1(\text{repeat}) > PC1(\text{single}) > PC1(\text{double}) > PC1(\text{multi})$$

对应假设：T3'（语义越窄，PC1 越高）。

3.3 实验流程

所有实验遵循统一流程：

1. **加载模型**：使用 `AutoModelForCausalLM` 与 `AutoTokenizer`；
2. **注册 Hook**：在每层 `attn` 模块注册 `forward hook`，提取 Q/K/V；
3. **前向传播**：输入文本，收集所有层的 Q/K/V；
4. **计算度量**：逐层逐头计算方案 A/B/C、局部 PCA、熵等；
5. **消融实验**：注册消融 `hook`，重复前向传播，计算性能变化；
6. **累积消融**：逐步增加消融层数，记录性能曲线；
7. **受控领域实验**：更换输入文本，重复步骤 3–4；
8. **可视化**：生成热力图、散点图、层趋势图。

随机性控制：

- 所有实验使用 `model.eval()` 模式；
- 不涉及训练，无随机种子问题；
- 对于消融实验，使用相同的输入文本与测试集。

计算资源：

- 所有实验在单张 GPU（如 NVIDIA T4 或 V100）上运行；
- 单个实验耗时数秒至数分钟，完整复现约需 1 小时。

3.4 小结

本节定义了六类度量指标，分别对应关系体几何中的不同理论预测。方案 A/B/C 用于检验局部冗余与全局主干，局部 PCA 用于量化局部树干强度，消融实验用于验证冗余补偿定理，受控领域实验用于直接操控语义宽度变量。所有指标均基于单次前向传播或简单消融，计算高效、可复现。

4. 实验结果

本节呈现基于第 3 节度量指标的全部实验结果。实验按逻辑顺序组织：首先验证局部冗余的普遍性（4.1），其次检验全局主干假设（4.2），然后量化局部树干强度（4.3），再进行跨模型验证（4.4）。在此基础上，深入分析高 PC1 头的功能（4.5）、Layer 11 的语义出口机制（4.6）、消融与冗余补偿（4.7），最后给出受控领域实验的核心因果证据（4.8）。

4.1 局部冗余的普遍性（方案 A）

4.1.1 GPT-2 small

对 GPT-2 small 的全部 144 个（层，头）对，计算方案 A 的相关系数 r_A 。

指标	数值
均值 r_A	-0.6783
负相关比例	100.00%
最大负相关	-0.9333（Layer 8, Head 1）
最小负相关	-0.2242（Layer 11, Head 8）

结论：所有层、所有头均呈现局部冗余，即高注意力概率对应低局部差异度。这验证了假设 H1。

4.1.2 GPT-2 medium

对 GPT-2 medium 的全部 384 个（层，头）对，计算方案 A。

指标	数值
均值 r_A	-0.6657
负相关比例	99.74%
最大负相关	-0.9482（Layer 9, Head 9）
最小负相关	+0.0780（Layer 1, Head 15）

结论：GPT-2 medium 与 small 几乎一致，局部冗余是 Transformer 的普遍属性，不随模型规模改变。

4.1.3 小结

高概率 $\Rightarrow$ 高局部冗余 ($r_A < 0$) 是跨模型、跨层、跨头的普遍规律。

(a) Scheme A: Local redundancy




图 2(a)：方案 A 散点图（局部差异度 vs 注意力概率）。




图 A2：跨模型 r_A 分布直方图（GPT-2 small 与 medium 几乎重合，集中在 -0.8 到 -0.5）。

4.2 全局主干假设的检验（方案 B/C）

4.2.1 方案 B：全局主成分能量

模型	均值 r_B	正相关比例
GPT-2 small	-0.3129	16.67%
GPT-2 medium	-0.3578	12.50%

结论：高概率 token 在全局主成分上的能量占比不升反降。假设 H2（存在全局主干）被否定。

4.2.2 方案 C：全局残差范数

模型	均值 r_C	负相关比例
GPT-2 small	-0.4006	89.58%
GPT-2 medium	-0.4213	91.15%

结论：高概率 token 残差较小，被全局主成分部分解释。但由于方案 B 已否定全局主干，方案 C 的负相关只能说明全局主成分虽无主干，但仍能部分覆盖高概率 token。

4.2.3 小结

全局无主干：能量分散，无贯穿全局的主方向。

全局主成分只能部分解释高概率 token，不足以构成“树干”。

(b) Scheme B: Global PC energy




图 2(b): 方案 B 散点图 (全局主成分能量 vs 平均注意力概率)。




图 2(c): 方案 C 散点图 (全局残差范数 vs 平均注意力概率)。

4.3 局部树干强度 (局部 PCA)

4.3.1 GPT-2 small

对每个 query 取 top-10 高概率 token，计算 PC1 集中度。

指标	数值
均值 PC1	0.3436

指标	数值
随机基线 $1/d_h$	0.0156
最大值	0.6829 (Layer 1, Head 11)
最小值	0.2588
PC1 > 0.3 比例	82.64%
PC1 > 0.5 比例	2.08%
平均 $r(\text{conc}, \text{entropy})$	-0.4058

4.3.2 GPT-2 medium

指标	数值
均值 PC1	0.3595
随机基线 $1/d_h$	0.0156
最大值	0.7523 (Layer 23, Head 4)
最小值	0.2588
PC1 > 0.3 比例	91.15%
PC1 > 0.5 比例	8.33%
平均 $r(\text{conc}, \text{entropy})$	-0.4271

4.3.3 小结

局部存在叶柄：PC1 均值 0.34–0.36，远高于随机基线。

但不是粗主干：PC1 未达到 0.8 以上，绝大多数头在 0.3–0.5 之间。

注意力越集中（熵越低），局部树干越强（PC1 越高）。

完整的 PC1 层×头分布见附录图 A1（GPT-2 medium）。

4.4 跨模型验证

4.4.1 层趋势一致性

模型	浅层 PC1 (0–2)	中层 PC1 (3–10)	深层 PC1 (11+)
GPT-2 small	0.40	0.32	0.35
GPT-2 medium	0.47	0.32	0.43

结论：两个模型都呈现 U 形曲线：浅层高、中层低、深层回升。

4.4.2 PC1 与模型规模无关

模型	head_dim	平均 PC1
GPT-2 small	64	0.3436
GPT-2 medium	64	0.3595

结论：PC1 集中度由 head_dim 决定，与模型层数、头数、参数量几乎无关。

4.4.3 小结

局部叶柄强度由 head_dim 决定，与模型规模无关。

层趋势（浅强、中弱、深回升）是 Transformer 的普遍规律。




图 A5：跨模型层趋势对比； r_A 分布对比见附录图 A2。

4.5 高 PC1 头的功能分析（实验 2）

4.5.1 高 PC1 头：Layer 1, Head 11

指标	数值
PC1	0.6829
平均熵	1.0192
平均 Top-1 概率	0.6954
Top-1 目标分布	自身 + 句首 "The" + 标点

行为特征：

- 注意力矩阵呈强对角线（关注自身）；
- 在句号位置跳到句首 "The"；
- 少数跨词关注（如 "cat" 关注 "The"）。

功能标签：位置锚定头 + 句首边界头。

4.5.2 低 PC1 头：Layer 3, Head 1

指标	数值
PC1	0.2899
平均熵	1.4071
行为特征	注意力弥散，无固定模式

功能标签：语义头（通用、分散）。

4.5.3 对比

头	PC1	熵	功能
L1 H11	0.68	1.02	位置/句法
L3 H1	0.29	1.41	语义

熵差： $1.4071 - 1.0192 = 0.3879$ 。

4.5.4 小结

高 PC1 头 = 低熵 = 结构头（句法/位置）。

低 PC1 头 = 高熵 = 语义头（通用/分散）。




图 3：高 PC1 头（L1 H11）与低 PC1 头（L3 H1）的注意力矩阵对比。

4.6 Layer 11 语义出口与顶端优势（实验 C）

4.6.1 逐头消融

对 Layer 11 的 12 个头逐个消融，测量语义 Δ 。

Head	语义 Δ	PC1	熵	排名
7	-0.1422	0.324	1.030	1
5	-0.0683	0.292	0.790	2
1	-0.0587	0.296	1.301	3
4	-0.0563	0.340	1.261	4
8	-0.0048	0.546	2.010	11

4.6.2 Head 7 的注意力目标

Top-1 target distribution (Head 7):

'The': 31 times (100.0%)

所有 31 个 token 的 Top-1 目标都是句首 "The"。

4.6.3 功能定义

Head 7 = 全局语义广播头：从句首提取全局表示，广播到所有位置。

类比：植物的**顶端优势**——句首是顶芽，Head 7 是生长素，所有位置向句首汇聚。

4.6.4 Layer 0 vs Layer 11 对比

指标	Layer 0（入口）	Layer 11（出口）
平均 PC1	0.380	0.351
平均熵	1.739	1.338
最高 PC1 头	H10（0.484）	H8（0.546）
语义关键头	—	H7（PC1=0.324）

结论：入口发散，出口聚焦；出口关键头 PC1 中等，但功能不可替代。

4.6.5 小结

Layer 11 Head 7 = 全局语义广播头，100% 关注句首。

高 PC1 = 结构冗余；中等 PC1 = 语义关键。




图 4：Layer 11 Head 7 的注意力矩阵热力图，100% 关注句首。

4.7 消融与冗余补偿（实验 1）

4.7.1 单头消融

对代表性头进行单头消融，效应均在 ± 0.025 以内。

头	句法 Δ	语义 Δ
L1 H11	+0.0116	-0.0010
L3 H1	-0.0120	-0.0121

头	句法 Δ	语义 Δ
L5 H5	+0.0048	-0.0078
L11 H8	+0.0249	-0.0197

结论：单头消融被多头冗余完全补偿。

4.7.2 整层消融

层	句法 Δ	语义 Δ	解读
L0	-2.6228	-3.5400	信息入口瓶颈
L1	-0.1152	-0.0359	轻微
L2–L10	± 0.2 以内	± 0.2 以内	冗余补偿
L11	-0.1091	-0.7619	语义出口

结论：入口/出口是瓶颈，中间层高度冗余。

4.7.3 累积消融

k	消融层	句法 Δ	语义 Δ
0	无	0	0
3	[1,2,3]	-0.32	-0.23
4	[1,2,3,4]	-0.97	-0.83
5	[1–5]	-1.09	-1.24
10	[1–10]	-1.85	-3.63

相变点： $k^* = 4$ ，此后冗余补偿失效，性能急剧下降。

4.7.4 小结

$$\Delta_{\text{Layer 0}} \gg \Delta_{\text{Layer 11}} \gg \Delta_{\text{middle}} \gg \Delta_{\text{single head}}$$

累积消融在 $k^* = 4$ 处出现相变：冗余补偿有上限。

表 4.2：消融效应汇总。

消融粒度	句法 Δ	语义 Δ	备注
单头消融	± 0.025	± 0.025	被多头冗余补偿
中间层消融 (L2–L10)	± 0.2	± 0.2	被其他层补偿
入口层消融 (L0)	-2.62	-3.54	信息入口瓶颈
出口层消融 (L11)	-0.11	-0.76	语义出口瓶颈
累积消融 $k = 4$	-0.97	-0.83	相变点
累积消融 $k = 10$	-1.85	-3.63	冗余耗尽




图 5：累积消融曲线与相变点 $k^* = 4$ 。

4.8 受控领域实验（实验 D）

4.8.1 PC1 vs 语义宽度

领域	语义宽度	平均 PC1	标准差
repeat	极窄	0.7637	0.1147
single	窄	0.3773	0.0637

领域	语义宽度	平均 PC1	标准差
double	中	0.3231	0.0569
multi	宽	0.3079	0.0533

4.8.2 单调性检验

Monotonically decreasing: True
Hypothesis SUPPORTED

PC1(repeat) > PC1(single) > PC1(double) > PC1(multi)

4.8.3 层趋势

- repeat: 所有层 PC1 在 0.6–0.9，浅层最高；
- single/double/multi: PC1 在 0.3–0.45，呈 U 形；
- 三条宽领域曲线几乎重合。

4.8.4 rA 分布

- 所有领域 r_A 均值 ≈ -0.46 ；
- repeat 分布最宽 (-1.0 到 +0.4)；
- 其他三个领域集中在 -0.6 到 -0.2。

结论：局部冗余是架构属性，与语义宽度无关。

4.8.5 小结

语义越窄 $\Rightarrow$ PC1 越高 $\Rightarrow$ 越接近有主干的传统树。

稠密模型（宽语义） $\Rightarrow$ PC1 $\approx$ 0.31–0.34 $\Rightarrow$ 灌木丛。




图 6：PC1 vs 语义宽度柱状图 + 层趋势 + rA 分布 + PC1 热力图。

4.9 实验结果总览

实验	核心发现	对应假设	状态
4.1 局部冗余	100% 负相关	H1	是
4.2 全局无主干	r_B 负相关	H2	否（否定）
4.3 局部 PCA	PC1=0.34，远高于随机	H4	是
4.4 跨模型	PC1 由 head_dim 决定	T3	是
4.5 高 PC1 头	结构头（低熵）	T2.1	是

实验	核心发现	对应假设	状态
4.6 Layer 11	全局语义广播头	T4.1	是
4.7 消融	入口/出口瓶颈，相变 $k^* = 4$	T4	是
4.8 受控领域	语义窄 $\rightarrow$ PC1 高	T3'	是

核心结论：

注意力机制 = 全局无主干 + 局部有叶柄 + 头间功能分化 + 层间冗余补偿。

语义宽度是 PC1 的因果决定因素。

稠密模型是灌木丛，MoE 专家预测为传统树。

5. 讨论

本节整合第 4 节的实验发现，提出“无主干灌木丛”模型，讨论其与现有可解释性研究的关系，给出对混合专家（MoE）模型的可证伪预测，并说明当前工作的局限与未来方向。

5.1 无主干灌木丛模型

综合第 4 节的全部实验结果，我们可以将训练后 Transformer 的注意力几何结构概括为：

全局无主干 + 局部有叶柄 + 头间功能分化 + 层间冗余补偿

这一结构被称为“无主干灌木丛”。

5.1.1 全局无主干

方案 B 与方案 C 表明，高概率 token 在全球主成分上的能量占比不升反降，全局奇异值谱接近 Marchenko-Pastur 分布，没有孤立的大特征值。这意味着不存在贯穿整个序列的“粗树干”。

全局语义分布宽 $\Rightarrow$ PC1 $\rightarrow 1/d_h \Rightarrow$ 无主干。

5.1.2 局部有叶柄

局部 PCA 显示，每个 query 的 top- k 高概率 token 的 Value 向量存在一个主导方向（PC1 均值约 0.34，远高于随机基线 0.0156）。这对应“叶柄”——局部结构中心。

局部语义聚集 $\Rightarrow$ PC1 $\gg 1/d_h \Rightarrow$ 有叶柄。

5.1.3 头间功能分化

实验 2 与实验 C 表明：

- 高 PC1 头：低熵、专精，对应句法/位置功能（如 L1 H11）；
- 低 PC1 头：高熵、通用，对应语义功能（如 L3 H1）；
- Layer 11 Head 7：PC1 中等（0.324），但语义贡献最大，功能为“全局语义广播头”。

高 PC1 = 结构冗余；低 PC1 = 语义多样；中等 PC1 = 关键广播。

5.1.4 层间冗余补偿

消融实验表明：

- 单头消融：效应 ± 0.025 ，几乎无影响；
- 中间层消融：效应 ± 0.2 ，被其他层补偿；
- 入口层（L0）消融：效应 -2.6 （句法）、 -3.5 （语义），信息瓶颈；
- 出口层（L11）消融：语义 $\Delta = -0.76$ ，语义出口瓶颈；
- 累积消融：在 $k^* = 4$ 处出现相变，冗余补偿有上限。

入口/出口是瓶颈，中间层是冗余灌木丛，相变点 $k^* = 4$ 。

5.2 与现有可解释性研究的关系

5.2.1 注意力头功能分类

现有研究已识别出多种功能头：位置头、语法头、归纳头、指代头等。本文的工作为这些功能标签提供了统一的几何解释：

功能头 = 关系体上的特定区域（高 c 或高 s ）。

- 高 PC1 头：对应高 c （相同/平行），低熵，结构功能；

- 低 PC1 头：对应高 s （不同/正交），高熵，语义功能。

5.2.2 稀疏自编码器（SAE）

SAE 通过字典学习分解神经元激活，寻找可解释特征。本文的关系体几何可以视为 SAE 的几何对偶：

SAE 寻找稀疏方向；关系体寻找冗余-独立平衡。

两者都试图揭示隐藏表示的结构，但本文从内积/外积的第一性原理出发，提供了更底层的几何语言。

5.2.3 因果追踪与消融

本文的消融实验与因果追踪方法一致，但进一步量化了：

- 入口/出口瓶颈；
- 中间层冗余补偿；
- 相变点 $k^* = 4$ 。

这些结果为因果追踪提供了新的理论视角。

5.2.4 与“归纳头”的关系

归纳头（Induction Head）负责模式补全，是上下文学习的核心。在关系体框架下，归纳头对应于：

高 c （相同） + 高 s （不同） $\Rightarrow$ 强模式匹配。

其 PC1 可能介于结构头与语义头之间，是关系体上的“对角线区域”。

5.3 对 MoE 的可证伪预测

基于 T3'（语义宽度定理），我们提出对混合专家（MoE）模型的核心预测：

单个专家的 PC1 应显著高于稠密模型。

5.3.1 理论依据

MoE 中，每个专家只处理特定子领域（如数学、代码、法语），其训练语义分布 D_{sem} 远窄于稠密模型。由 T3'：

$$PC1 \propto \frac{1}{D_{sem}}$$

因此：

专家语义窄 $\Rightarrow$ PC1 高 $\Rightarrow$ 更接近有主干的传统树。

5.3.2 预测数值

模型类型	预期 PC1	预期结构
稠密模型（GPT-2）	0.31–0.36	灌木丛
单个专家	> 0.5	传统树（有主干）

5.3.3 验证方案

1. 加载开源 MoE 模型（如 Mixtral、Qwen-MoE）；
2. Hook 路由层，标记每个 token 的专家分配；
3. 对每个专家单独收集 QKV；
4. 对每个专家重复本文的全局 PCA + 局部 PCA 分析；
5. 对比稠密模型与专家的 PC1。

如果专家 PC1 显著高于稠密模型，则 T3' 得到支持；如果专家 PC1 仍在 0.34 附近，则假设被否定。

5.3.4 进一步预测

- 专家的 PC1 应与其训练数据宽度负相关；
- 专家内部的头间方差应小于稠密模型；
- 专家的层趋势应更平坦（因为语义窄，PC1 不随层剧烈变化）。

5.4 因果掩码下的“被动涌现”现象

本文实验揭示了一个重要的架构不对称性：

因果掩码禁止反向广播，导致全局语义只能“被动涌现”。

在标准 GPT-2 中：

- 前 11 层：各 token 独立演绎，无全局同步；

- 句首：通过残差流被动累积信息，无法主动整合；
- 第 12 层：L11 H7 让所有 token 读取句首，实现“伪全局同步”。

这一发现解释了为什么：

- L11 H7 必须存在（补偿反向广播缺失）；
- L11 H7 的消融效应最大（语义 $\Delta = -0.14$ ）；
- 因果 Transformer 的全局表示是“涌现”而非“构建”的。

标准 Transformer：伪全局（被动累积 + 末端广播）。

这一观察也为未来工作（如打破因果掩码的双向广播模型）提供了动机。

5.5 局限

本文工作存在以下局限：

1. **模型范围**：实验主要在 GPT-2 small 与 medium 上进行，尚未验证更大模型（如 LLaMA、Qwen）与 MoE。
2. **序列长度**：输入文本长度有限（31–150 token），更长序列可能呈现不同规律。
3. **受控领域实验**：repeat/single/double/multi 是人为构造，非自然训练分布。
4. **因果掩码**：本文仅分析标准因果 Transformer，未涉及双向注意力（如 BERT）。
5. **理论假设**：T2 的 QKV 对齐假设、T3 的随机投影假设均为近似，需要更多经验验证。
6. **MoE 预测**：尚未在真实 MoE 模型上验证。

5.6 未来工作

基于本文发现，未来工作可从以下方向展开：

1. **MoE 验证**：在真实 MoE 模型上检验专家 PC1 是否显著高于稠密模型。
2. **更大模型**：在 LLaMA、Qwen 等模型上重复本文实验，验证规律的普遍性。
3. **双向广播模型**：设计打破因果掩码、允许反向广播的架构，检验是否能主动构建全局表示。
4. **自组织生长模型**：基于关系体几何，设计不预设 QKV/softmax 的生成路径，观察信息树的自发涌现（见 v1.0 工作）。
5. **几何可解释性工具包**：将本文的度量指标（方案 A/B/C、局部 PCA、消融）封装为开源工具，供社区使用。

6. 理论深化：严格证明 T3 的 Marchenko-Pastur 近似，放宽假设 A4。

5.7 小结

注意力机制 = 全局无主干 + 局部有叶柄 + 头间功能分化 + 层间冗余补偿。

语义宽度是 PC1 的因果决定因素。

稠密模型是灌木丛，MoE 专家预测为传统树。

因果掩码导致全局语义“被动涌现”，而非“主动构建”。

这些结论为理解 Transformer 内部信息几何提供了统一语言，并为下一代架构设计提供了可检验的方向。

6. 结论与未来工作

6.1 结论

本文从内积与外积的基本恒等式出发，建立了一个统一的几何框架——关系体几何，用于理解 Transformer 注意力机制的信息组织方式。主要结论如下：

6.1.1 理论贡献

我们证明了关系体定理 (T1)：任意两个非零向量的关系可归一化为单位圆上的点，满足 $c^2 + s^2 = 1$ 。在此基础上，推导了三个核心定理：

- **T2 (冗余-概率定理)**：高注意力概率对应高局部冗余；
- **T3 (无主干定理)**：宽语义分布导致全局 PC1 趋近随机基线，不存在贯穿全局的主干；
- **T4 (冗余补偿定理)**：入口层与出口层是信息瓶颈，中间层具有高度冗余补偿能力。

这些定理共同刻画了注意力机制的几何本质：

注意力机制 = 关系体上的信息组织过程。

6.1.2 实验发现

在 GPT-2 small 与 GPT-2 medium 上的系统实验揭示了以下规律：

- 1. **局部冗余的普遍性**：所有层、所有头均呈现 $r_A < 0$ （100% 负相关），高概率 token 趋同于上下文均值；
- 2. **全局无主干**：方案 B/C 表明全局主成分无法解释高概率 token，能量分散；
- 3. **局部有叶柄**：局部 PCA 均值约 0.34，远高于随机基线 0.0156；
- 4. **头间功能分化**：高 PC1 头对应句法/位置功能（低熵），低 PC1 头对应语义功能（高熵）；
- 5. **语义出口广播**：Layer 11 Head 7 是全球语义广播头，100% 关注句首，功能不可替代；
- 6. **冗余补偿与相变**：累积消融在 $k^* = 4$ 处出现相变，冗余补偿有上限；
- 7. **受控领域因果验证**：输入语义越窄，PC1 越高，单调递减关系成立。

6.1.3 核心结论

稠密模型 = 无主干灌木丛（全局分散，局部有结构）。

语义宽度是 PC1 的因果决定因素：语义越窄，PC1 越高。

因果掩码导致全局语义“被动涌现”，而非“主动构建”。

6.1.4 可证伪预测

本文提出以下尚未验证的预测，供后续工作检验：

预测	内容	状态
P1	输入语义越窄，PC1 越高	已验证（实验 D）
P2	MoE 单个专家 PC1 显著高于稠密模型	待验证
P3	消融入口/出口层效应远大于中间层	已验证（实验 1）
P4	高 PC1 头对应句法/位置，低 PC1 头对应语义	已验证（实验 2）

6.2 理论意义

6.2.1 统一了几何与信息论

关系体几何将内积（相似性）、外积（差异性）、信息熵、主成分集中度统一在一个框架内：

相似 $\leftrightarrow c$, 差异 $\leftrightarrow s$, 冗余 $\leftrightarrow 1/\Delta$, 集中 $\leftrightarrow \text{PC1}$ 。

6.2.2 解释了“为什么注意力有效”

注意力机制的有效性不在于“软检索”或“核平滑”这类局部解释，而在于它同时完成了两件事：

- 用高概率建立**结构骨架**（句法/位置）；
- 用低概率保留**信息多样性**（语义/长尾）。

注意力 = 结构 + 多样性，二者通过关系体守恒。

6.2.3 指出了因果 Transformer 的架构局限

因果掩码禁止反向广播，导致全局语义只能被动涌现。这是当前架构的一个根本性限制，也是未来改进的方向。

6.3 未来工作

6.3.1 MoE 专家验证（优先级最高）

本文最重要的待验证预测是 MoE 专家的 PC1 是否显著高于稠密模型。具体方案：

1. 加载开源 MoE 模型（如 Mixtral-8x7B、Qwen-MoE）；
2. Hook 路由层，标记每个 token 的专家分配；
3. 对每个专家单独收集 QKV；
4. 重复本文的全局 PCA + 局部 PCA 分析；
5. 对比专家与稠密模型的 PC1。

如果专家 PC1 显著高于 0.5，则 T3' 得到支持；如果仍在 0.34 附近，则假设需要修正。

6.3.2 更大模型验证

在 LLaMA、Qwen、DeepSeek 等模型上重复本文实验，验证以下规律的普遍性：

- 局部冗余的 100% 负相关；
- 层趋势的 U 形曲线；
- 出口层的语义广播头；
- 累积消融的相变点。

6.3.3 双向广播模型

设计打破因果掩码、允许反向广播的架构，检验是否能主动构建全局表示。核心问题：

双向广播是否能让模型从“灌木丛”变为“有主干的树”？

6.3.4 自组织生长模型

基于关系体几何，设计不预设 QKV/softmax 的生成路径，观察信息树的自发涌现。这是另一篇论文 v1.0 工作的核心方向，具体包括：

- 聚合、锚定、扩展、广播四机制的竞争与协同；
- 相变点 $\rho_0/\nu_0 \approx 1.0$ 的解析推导；
- 有向相位 $e^{i\theta}$ 的引入与验证。

6.3.5 几何可解释性工具包

将本文的度量指标（方案 A/B/C、局部 PCA、消融、受控领域实验）封装为开源工具，供社区使用。工具包应包含：

- 一键提取 QKV；
- 自动计算所有度量；
- 生成标准可视化图表；
- 支持任意 HuggingFace 模型。

6.3.6 理论深化

- 严格证明 T3 的 Marchenko-Pastur 近似，放宽假设 A4；
- 解析推导 T4 的相变点 k^* ；
- 将关系体几何推广到多头、多层、MoE 的统一框架。

6.4 最终展望

本文从一个简单的数学事实——内积与外积的归一化——出发，构建了一个统一理解 Transformer 注意力机制的几何框架。这一框架不仅解释了现有实验现象，还给出了可证伪的预测，并为下一代架构设计提供了方向。

从勾股定理到 Transformer，关系体几何提供了一条自洽的路径。

注意力机制的本质：在关系体上，用相同建立结构，用不同保留多样性。

下一站：MoE 验证与双向广播模型。

我们希望这一工作能激发更多关于大模型内部几何结构的理论探索，推动可解释性研究从“现象描述”走向“理论预测”，最终实现对大模型信息处理的完整理解。

附录

附录 A：数学证明

A.1 关系体定理（T1）完整证明

设 $a, b \in \mathbb{R}^d$ 为非零向量，定义关系坐标：

$$c(a, b) = \frac{\langle a, b \rangle}{\|a\| \|b\|}, \quad s(a, b) = \frac{\|a \wedge b\|}{\|a\| \|b\|}$$

外积范数恒等式为：

$$\|a \wedge b\|^2 = \|a\|^2 \|b\|^2 - \langle a, b \rangle^2$$

两边除以 $\|a\|^2 \|b\|^2$ ：

$$\frac{\|a \wedge b\|^2}{\|a\|^2 \|b\|^2} = 1 - \frac{\langle a, b \rangle^2}{\|a\|^2 \|b\|^2}$$

即 $s^2 = 1 - c^2$ ，因此：

$$c^2 + s^2 = 1$$

证毕。■

A.2 冗余-概率定理（T2）完整证明

设定：注意力概率 $p_{ij} = \text{softmax}(q_i \cdot k_j / \sqrt{d_h})$ ，上下文加权平均 $\bar{V}_i = \sum_j p_{ij} V_j$ ，局部差异度 $\Delta_{ij} = \|V_j - \bar{V}_i\|$ 。

假设 A1：存在 $\lambda > 0$ ，使得 $q_i \cdot k_j \approx \lambda v_i \cdot v_j$ 。

假设 A2：Value 向量在局部形成聚集，中心为 μ_c 。

由 softmax 定义：

$$p_{ij} = \frac{\exp(q_i \cdot k_j / \sqrt{d_h})}{\sum_k \exp(q_i \cdot k_k / \sqrt{d_h})}$$

由 A1, $q_i \cdot k_j \approx \lambda v_i \cdot v_j$, 因此 p_{ij} 关于 $v_i \cdot v_j$ 单调递增。当 p_{ij} 高时, $v_i \cdot v_j$ 大, 说明 V_j 与 v_i 方向一致。由 A2, 局部聚集使得 $\bar{V}_i$ 也接近该聚集中心, 因此 $\bar{V}_i \approx V_j$, 从而 $\Delta_{ij} \approx 0$ 。

因此：

$$p_{ij} \uparrow \Rightarrow \mathbb{E}[\Delta_{ij}] \downarrow$$

证毕。■

A.3 无主干定理 (T3) 完整证明

假设 A3: 语义分布内在维度 $D_{\text{sem}} \gg d_h$ 。

假设 A4: Value 投影矩阵 W_V 在语义空间中近似为随机正交投影。

设 $V \in \mathbb{R}^{n \times d_h}$ 为 Value 矩阵, 协方差矩阵 $C = \frac{1}{n} V^T V$ 。

由 A4, V 的行向量近似独立同分布, 协方差矩阵 C 的特征值分布收敛到 Marchenko-Pastur 分布。MP 分布没有原子质量, 不存在孤立的大特征值。最大特征值近似为：

$$\lambda_{\max} \approx \sigma^2 (1 + \sqrt{\gamma})^2, \quad \gamma = \frac{d_h}{n}$$

总特征值之和为 $d_h \sigma^2$ 。因此：

$$\frac{\lambda_{\max}}{\sum_k \lambda_k} = \frac{(1 + \sqrt{\gamma})^2}{d_h} = O\left(\frac{1}{d_h}\right)$$

当 d_h 有限时, PC1 集中度趋近 $1/d_h$ 。

证毕。■

A.4 冗余补偿定理 (T4) 完整证明

假设 A5: 消融幅度不大时, 输出变化近似线性。

假设 A6: 结构头 PC1 高、熵低; 语义头 PC1 低、熵高。

消融效应 $\Delta_{l,h} = \|f(X) - f(X; \theta \setminus A_{l,h})\|$ 。

- **Layer 0 瓶颈:** Layer 0 是所有信息进入残差流的唯一通道, 消融它等于切断输入, 效应最大。

- **Layer L-1 出口**：最后一层直接输出到 logits，负责语义压缩，消融它破坏最终解码，效应次之。
- **中间层冗余**：由 T3，中间层语义维度最高，信息分散，消融一层可被其他层补偿，效应较小。
- **单头冗余**：多头设计中，每个头的贡献可被同层其他头部分补偿，效应最小。

因此：

$$\Delta_{\text{Layer}0} \gg \Delta_{\text{Layer}L-1} \gg \Delta_{\text{middle}} \gg \Delta_{\text{singlehead}}$$

证毕。■

附录 B：实验细节

B.1 模型加载与 Hook 实现

所有实验基于 HuggingFace Transformers 实现，模型为 GPT-2 small 与 GPT-2 medium。

模型加载：

```
from transformers import GPT2LMHeadModel, GPT2Tokenizer

model = GPT2LMHeadModel.from_pretrained("gpt2")
tokenizer = GPT2Tokenizer.from_pretrained("gpt2")
model.eval()
```

QKV 提取 Hook：

```
qkv_store = {}

def hook_fn(module, inp, out):
    qkv_store['out'] = out.detach()

hook = model.transformer.h[layer].attn.c_attn.register_forward_hook(hook_fn)
with torch.no_grad():
    model(**inputs)
hook.remove()

qkv = qkv_store['out'][0]
q, k, v = qkv.split(n_embd, dim=-1)
```

B.2 消融与激活修补实现

单头消融：

```
class HeadAblationHook:
    def __init__(self, layer, head, head_dim):
        self.layer = layer
        self.head = head
        self.head_dim = head_dim
        self.enabled = False

    def __call__(self, module, inp, out):
        if not self.enabled:
            return out

        attn_output = out[0].clone() if isinstance(out, tuple) else out.clone()
        start = self.head * self.head_dim
        end = start + self.head_dim
        attn_output[:, :, start:end] = 0.0
        return (attn_output,) + out[1:] if isinstance(out, tuple) else attn_output
```

整层消融：将 head 设为 None ，置零整个 attn_output 。

激活修补：将指定头的输出替换为该头在所有 token 上的均值。

B.3 受控领域文本

四种语义宽度的输入文本：

领域	语义宽度	示例内容
repeat	极窄	重复 "the" 30 次
single	窄	纯 Python 代码（阶乘、斐波那契、二叉树）
double	中	数学 + 诗歌混合
multi	宽	新闻 + 代码 + 数学 + 对话混合

B.4 测试集完整列表

句法测试集（60 题）：覆盖主谓一致、时态、代词、冠词、介词。

示例：

- The cat ____ on the mat. (is / are)
- Yesterday, she ____ to the store. (went / goes)
- John said ____ was tired. (he / they)
- ____ apple a day keeps the doctor away. (An / A)
- The book is ____ the table. (on / in)

语义测试集 (60 题)：覆盖词义选择、常识推理。

示例：

- The cat sat on the _____. (mat / sky)
- The fish swims in the _____. (water / tree)
- The sun rises in the _____. (east / west)
- She drank a cup of _____. (coffee / bread)
- The bird flew over the _____. (house / water)

完整测试集见 `code/analysis/ablation_v2.py` 。

附录 C：补充图表

- 图 A1：GPT-2 medium 完整 PC1 热力图
- 图 A2：所有层所有头的 rA 分布
- 图 A3：SVD 奇异值谱
- 图 A4：多种子重复实验结果
- 图 A5：跨模型层趋势对比

参考文献

```
@inproceedings{vaswani2017attention,
  title={Attention is all you need},
  author={Vaswani, Ashish and Shazeer, Noam and Parmar, Niki and others},
  booktitle={Advances in Neural Information Processing Systems},
  year={2017}
}

@article{elhage2021mathematical,
  title={A mathematical framework for transformer circuits},
  author={Elhage, Nelson and Nanda, Neel and Olsson, Catherine and others},
  journal={Transformer Circuits Thread},
  year={2021}
}

@article{olsson2022context,
  title={In-context learning and induction heads},
  author={Olsson, Catherine and Elhage, Nelson and Nanda, Neel and others},
  journal={Transformer Circuits Thread},
  year={2022}
}

@article{bricken2023towards,
  title={Towards monosemanticity: Decomposing language models with dictionary learning},
  author={Bricken, Trenton and Templeton, Adly and Batson, Joshua and others},
  journal={Transformer Circuits Thread},
  year={2023}
}

@inproceedings{meng2022locating,
  title={Locating and editing factual associations in GPT},
  author={Meng, Kevin and Bau, David and Andonian, Alex and Belinkov, Yonatan},
  booktitle={Advances in Neural Information Processing Systems},
  year={2022}
}

@article{marchenko1967distribution,
  title={Distribution of eigenvalues for some sets of random matrices},
  author={Marchenko, Vladimir A and Pastur, Leonid A},
  journal={Matematicheskii Sbornik},
  year={1967}
```

}

```
@article{shazeer2017outrageously,  
  title={Outrageously large neural networks: The sparsely-gated mixture-of-experts layer},  
  author={Shazeer, Noam and Mirhoseini, Azalia and Maziarz, Krzysztof and others},  
  journal={International Conference on Learning Representations},  
  year={2017}  
}
```

```
@article{fedus2022switch,  
  title={Switch transformers: Scaling to trillion parameter models with simple and efficient sp},  
  author={Fedus, William and Zoph, Barret and Shazeer, Noam},  
  journal={Journal of Machine Learning Research},  
  year={2022}  
}
```

全文完。